

浪潮MetaX-C550、英伟达H100 - 单节点MiniMax-M2.5模型整体测试比对报告

*测试日期：2026-04-22 ~ 2026-04-26

*测试人员：九章云极

1. 测试背景

公司需要在多个候选开源大模型中选型，部署基于vLLM或SGLang的推理服务。并需要在满足各项模型服务指标的情况下，选定芯片集采厂商。

2. 测试目标

本测试主要评估不同芯片在单机环境下运行大模型推理的能力，为后续集群采购和生产部署提供决策依据。

- 硬件摸底**：确认各芯片型号实际规格（算力、显存、带宽）与标称值的一致性
- 功能验证**：各模型在各芯片环境上的推理正确性和算子兼容性
- 性能基准**：吞吐量、延迟、显存效率等关键指标
- 单机极限**：8卡 Tensor Parallel 的性能上限和资源利用率
- 稳定性验证**：长时间运行下的可靠性
- K8S 容器化验证**：单节点 K8S 环境下GPU/DCU/XPU 调度、资源管理和服务编排能力

3. 测试环境

3.1 硬件规格

组件 \ 规格	浪潮	英伟达	状态
节点数量	1 台	1 台	确认
芯片型号	MetaX-C550	H100	确认
芯片数量	8 张	8 张	确认
单卡算力 FP16/BF16	待确认	1979 TFLOPS （官方理论值）	⚠ 待 确认
单卡算力 FP32	待确认	67 TFLOPS （官方理论值）	⚠ 待 确认
单卡算力 FP64	待确认	34 TFLOPS （官方理论值）	⚠ 待 确认
单卡显存	64GB	80GB	确认
显存类型	HBM2e	HBM3	确认
显存带宽	待确认	3.35 TB/s	⚠ 待 确认
单卡功耗	450 W	700 W	确认
卡间互联	MetaXLink	NVLink 4.0	确认
CPU	Intel(R) Xeon(R) Platinum 8480+ (224核)	Intel(R) Xeon(R) Platinum 8468 (192核)	确认
系统内存	1.8 TiB	2.0 TiB	确认
本地存储	446.6GB + NVMe 4 x 7T	894GB 系统盘 + 7TB*4 缓存盘 + 7TB 容器盘 + 25TB 扩展盘	确认

3.2 软件栈

组件\版本	浪潮	英伟达	说明
操作系统	Ubuntu 20.04.1	Ubuntu 22.04.5 LTS	芯片所在物理机系统
显卡驱动	Kernel Mode Driver Version: 3.6.11	570.133.20/580.126.09	驱动信息
Toolkit	MACA Version: 3.5.3.23	release 12.9	CUDA Toolkit版本
Docker	28.1.1	-	容器运行时
containerd	-	2.2.0	K8S 容器运行时 (CRI)
Kubernetes	-	1.34.2	单节点 All-in-One 部署
Device Plugin	-	0.14.5	K8S GPU 资源管理
多卡通信库	MCCLI	NCCL	多卡通信库

3.3 模型配置信息

芯片名称	MetaX-C550	NVIDIA-H100
model_name	MiniMax-M2.5-W8A8	MiniMax-M2.5
quantization_config	int-8	FP8
model_size	215G	215G
max_position_embeddings	196608	196608
temperature	N/A	1.0
top_p	0.95	0.95
top_k	40	40
transformers_version	4.57.6	4.46.1
vllm_version	-	0.20.0
sglang_version	0.5.9+maca3.5.3.204	-
python_version	3.10.12	3.12.3

3.4 推理框架主要启动参数

参数名称（sglang）	MetaX-C550	NVIDIA-H100
max-model-len (context-length)	196608	196608
max-num-seqs (max-running-requests)	64	64
max-num-batched-tokens	-	8192
gpu-memory-utilization	-	0.85
mem-fraction-static	0.9	-
dp	1	1
tp	8	8
pp	1	1
enable-export-parallel	-	true
enable-auto-tool-choice	true	true
tool-call-parser	minimax-m2	minimax_m2
reasoning-parser	minimax	minimax_m2
disable-radix-cache	true	-
disable-chunked-prefix-cache	true	-

MetaX-C550平台，Minimax-M2.5模型详细部署完整脚本见本报告《附录一》

4. 测试场景及概况

4.1 测试场景列表

序号	测试场景
场景一	sglang benchmark基准测试
场景二	单、多并发超长上下文请求
场景三	多并发长上下文极限验证
场景四	多I/O测试
场景五	模型精度测试
场景六	模型推理功能测试

4.2 模型部署问题汇总

N/A

4.3 模型推理测试问题汇总

- 关闭思考模式不生效，关闭思考模式后，请求响应输出依然有思考模型下的content: 如果parser是 minimax-append-think, 思考的内容会在content里以...标签对包裹。如果parser是minimax，思考的内容会直接显示在reasoning_content里

以下是每个测试场景的详细结果报告

MetaX-C550平台，Minimax-M2.5模型benchmark测试脚本见本报告 《附录二》

测试场景一：sglang/vllm benchmark基准测试

测试目标：在相同请求数、基础长度上下文参数下，使用sglang/vllm bench serve工具对并发数逐级增加场景的性能基准验证。

主要采集指标：


指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

测试概览


项目	配置	备注
数据集	random	
并发数	1, 2, 4, 8, 10, 16, 32, 64, 80, 128	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
被测芯片	inspur_MetaX_C550, nvidia_h100	
被测模型	inspur_MetaX_C550 (MiniMax-M2.5-W8A8), nvidia_h100 (MiniMax-M2.5)	

芯片性能对比柱状图


1并发




2并发




4并发




8并发




10并发




16并发




32并发




64并发




80并发



128并发



性能趋势对比图 (所有芯片)



 各指标随并发级别性能对比详情

请求吞吐量 (Request throughput (req/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	0.45 ★	0.27	-0.18	-40.0%
2	0.78 ★	0.41	-0.37	-47.4%
4	1.26 ★	0.63	-0.63	-50.0%
8	1.82 ★	0.83	-0.99	-54.4%
10	2.09 ★	0.91	-1.18	-56.5%
16	2.51 ★	1.08	-1.43	-57.0%
32	3.12 ★	1.27	-1.85	-59.3%
64	3.66 ★	1.40	-2.26	-61.7%
80	3.67 ★	1.41	-2.26	-61.6%
128	3.66 ★	1.41	-2.25	-61.5%

输出token吞吐量 (Output token throughput (tok/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	115.31 ★	69.26	-46.05	-39.9%
2	199.70 ★	105.76	-93.94	-47.0%
4	323.45 ★	161.40	-162.05	-50.1%
8	465.99 ★	213.59	-252.40	-54.2%
10	534.52 ★	232.70	-301.82	-56.5%
16	643.80 ★	276.80	-367.00	-57.0%
32	797.81 ★	324.93	-472.88	-59.3%
64	937.16 ★	359.62	-577.54	-61.6%
80	938.91 ★	360.13	-578.78	-61.6%
128	937.61 ★	359.90	-577.71	-61.6%

总token吞吐量 (Total token throughput (tok/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	4745.14 ★	2839.48	-1905.66	-40.2%
2	8217.92 ★	4336.07	-3881.85	-47.2%
4	13310.92 ★	6617.46	-6693.46	-50.3%
8	19176.39 ★	8757.21	-10419.18	-54.3%
10	21996.95 ★	9540.82	-12456.13	-56.6%
16	26494.03 ★	11348.92	-15145.11	-57.2%
32	32831.81 ★	13322.11	-19509.70	-59.4%
64	38566.45 ★	14744.38	-23822.07	-61.8%
80	38638.21 ★	14765.49	-23872.72	-61.8%
128	38585.00 ★	14756.01	-23828.99	-61.8%

首token延迟 (P99 TTFT (ms))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	286.01	596.38	+310.37	+108.5%
2	466.40	1097.81	+631.41	+135.4%
4	826.89	2137.97	+1311.08	+158.6%
8	1364.44	4216.68	+2852.24	+209.0%
10	1534.23	5277.45	+3743.22	+244.0%
16	2630.84	8059.86	+5429.02	+206.4%
32	6556.86	15782.91	+9226.05	+140.7%
64	12557.76	31672.66	+19114.90	+152.2%
80	19679.20	53556.78	+33877.58	+172.1%
128	29645.32	76792.15	+47146.83	+159.0%

每token生成时间（P99 TPOT (ms)）

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	7.68	12.44	+4.76	+62.0%
2	9.05	15.89	+6.84	+75.6%
4	11.41	21.99	+10.58	+92.7%
8	35.95	34.97	-0.98	-2.7%
10	17.75	40.89	+23.14	+130.4%
16	23.92	55.86	+31.94	+133.5%
32	38.79	95.85	+57.06	+147.1%
64	66.03	174.61	+108.58	+164.4%
80	66.45	174.32	+107.87	+162.3%
128	66.52	174.13	+107.61	+161.8%

token间延迟（P99 ITL (ms)）

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	8.57	14.88	+6.31	+73.6%
2	16.54	19.00	+2.46	+14.9%
4	18.61	22.33	+3.72	+20.0%
8	152.68	27.01	-125.67	-82.3%
10	155.84	28.12	-127.72	-82.0%
16	161.83	31.26	-130.57	-80.7%
32	166.38	40.69	-125.69	-75.5%
64	170.95	57.22	-113.73	-66.5%
80	171.22	57.32	-113.90	-66.5%
128	170.62	57.60	-113.02	-66.2%

测试场景二：超长上下文请求测试


测试目标：对超长上下文的请求，使用sglang/vllm bench serve工具对并发数逐级增加场景的性能基准验证。

测试概览


项目	配置	备注
数据集	random	
并发数	1, 2, 4, 8, 10	
总请求数	100	
请求输入上下文长度	194560 (190k)	
请求输出上下文长度	1024 (1k)	
被测芯片	inspur_MetaX_C550, nvidia_h100	
被测模型	inspur_MetaX_C550 (MiniMax-M2.5-W8A8), nvidia_h100 (MiniMax-M2.5)	

芯片性能对比柱状图


1并发




2并发




4并发



8并发




10并发



 性能趋势对比图 (所有芯片)

MiniMax-M2.5 Performance Trends by Concurrency



各指标随并发级别性能对比详情

请求吞吐量（Request throughput (req/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	0.05 ★	0.01	-0.04	-80.0%
2	0.06 ★	0.01	-0.05	-83.3%
4	0.07 ★	0.01	-0.06	-85.7%
8	0.07 ★	0.01	-0.06	-85.7%
10	0.07 ★	0.01	-0.06	-85.7%

输出token吞吐量 (Output token throughput (tok/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	46.70 ★	12.69	-34.01	-72.8%
2	62.03 ★	13.67	-48.36	-78.0%
4	71.85 ★	14.34	-57.51	-80.0%
8	75.61 ★	14.35	-61.26	-81.0%
10	75.37 ★	14.34	-61.03	-81.0%

总token吞吐量 (Total token throughput (tok/s))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	8921.40 ★	2424.14	-6497.26	-72.8%
2	11850.06 ★	2610.79	-9239.27	-78.0%
4	13726.45 ★	2739.69	-10986.76	-80.0%
8	14443.68 ★	2741.37	-11702.31	-81.0%
10	14398.41 ★	2739.59	-11658.82	-81.0%

首token延迟 (P99 TTFT (ms))

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	10539.10	63374.54	+52835.44	+501.3%
2	20205.87	126438.40	+106232.53	+525.8%
4	37530.99	252746.14	+215215.15	+573.4%
8	81506.35	550123.80	+468617.45	+574.9%
10	108342.29	721962.01	+613619.72	+566.4%

每token生成时间（P99 TPOT (ms)）

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	11.39	20.33	+8.94	+78.5%
2	22.27	90.66	+68.39	+307.1%
4	45.32	228.93	+183.61	+405.1%
8	70.19	229.02	+158.83	+226.3%
10	69.61	229.15	+159.54	+229.2%

token间延迟（P99 ITL (ms)）

并发数	nvidia_h100	inspur_MetaX_C550	差值	百分比
1	22.97	24.42	+1.45	+6.3%
2	291.30	32.89	-258.41	-88.7%
4	518.54	46.66	-471.88	-91.0%
8	642.87	46.82	-596.05	-92.7%
10	639.97	46.84	-593.13	-92.7%

测试场景三：长上下文高并发极限验证

测试目标：多并发长上下文的情况下，验证各芯片单节点同时能处理的最大请求数。

 测试概览

项目	配置	备注
数据集	random	
并发数	32, 64	
总请求数	1000	
请求输入上下文长度	90000 (约90k)	
请求输出上下文长度	2000 (约2k)	
被测芯片	inspur_MetaX_C550, nvidia_h100	
被测模型	inspur_MetaX_C550 (MiniMax-M2.5-W8A8), nvidia_h100 (MiniMax-M2.5)	

监控处理请求极限

MetaX_C550芯片

Prefill阶段同时处理请求数：从0开始逐步增加到最高9

Decode阶段同时处理请求数：每批固定10个

nvidia_h100芯片


```
(APIServer pid=1007) INFO 04-30 16:07:48 [loggers.py:2
(APIServer pid=1007) INFO 04-30 16:07:58 [loggers.py:2
```

九章云极




芯片性能对比柱状图

32并发



64并发



 各并发级别性能对比详情

32 并发

指标	nvidia_h100	inspur_MetaX_C550
请求吞吐量（Request throughput (req/s)）	0.15 ★	0.04
输出token吞吐量（Output token throughput (tok/s)）	307.27 ★	74.75
总token吞吐量（Total token throughput (tok/s)）	14140.63 ★	3438.38
首token延迟（P99 TTFT (ms)）	151671.11 ★	857488.09
每token生成时间（P99 TPOT (ms)）	40.78 ★	124.93
token间延迟（P99 ITL (ms)）	363.93	58.30 ★

64 并发

指标	nvidia_h100	inspur_MetaX_C550
请求吞吐量（Request throughput (req/s)）	0.15 ★	0.04
输出token吞吐量（Output token throughput (tok/s)）	307.19 ★	74.77
总token吞吐量（Total token throughput (tok/s)）	14136.71 ★	3439.56
首token延迟（P99 TTFT (ms)）	345223.92 ★	1699446.48
每token生成时间（P99 TPOT (ms)）	40.79 ★	124.97
token间延迟（P99 ITL (ms)）	364.12	58.25 ★

测试场景四：多I/O测试

测试目标

测试不同输入输出长度和并发级别下的性能表现，分析同一芯片同一模型在不同输入输出长度和并发级别下的性能指标变化趋势。

测试概览


项目	配置	备注
数据集	random	
并发数	1, 4, 8, 16, 32, 64, 128	
总请求数	1000	
输入输出长度	(128, 128), (512, 256), (1024, 512), (2048, 1024), (4096, 2048), (8192, 1024)	
模型	MiniMax-M2.5-W8A8	
被测芯片	inspur_MetaX_C550	
SGLang版本	0.5.9	

各I/O测试汇总（随并发变化）

报告说明: 由于本测试场景比较多，此报告仅列出一组测试结果作为示例，且仅列出MetaX-C550测试结果

input: 8192, output: 1024

并发数	请求吞吐量 (req/s)	输出Token吞吐量 (tok/s)	总Token吞吐量 (tok/s)	TTFT P99 (ms)	TPOT P99 (ms)	E2E延迟均值 (ms)
1	0.08	78.29	704.57	520.17	12.47	13079.88
4	0.21	219.44	1975.00	1674.84	18.01	18663.66
8	0.32	322.67	2904.05	3159.86	24.60	25384.99
16	0.48	494.64	4451.74	6149.73	32.34	32912.17
32	0.66	673.65	6062.88	12147.10	46.88	48015.24
64	0.84	856.52	7708.66	23889.08	73.84	75139.87
128	0.84	857.26	7715.33	99741.36	73.69	146090.88




I/O对比（固定并发数, 随请求上下文长度变化）

并发数 = 1

指标	i128_o128	i512_o256	i1024_o512	i2048_o1024	i4096_o2048	i8192_o1
请求吞吐量 (req/s)	0.60	0.31	0.16	0.08	0.04	0.08
输出 Token 吞吐量 (tok/s)	77.40	80.35	81.65	82.15	81.37	78.29
总 Token 吞吐量 (tok/s)	154.81	241.04	244.96	246.46	244.12	704.57
TTFT P99 (ms)	153.05	156.87	158.39	159.25	217.04	520.17
TPOT P99 (ms)	11.97	11.99	12.03	12.08	12.22	12.47
E2E延 迟均值 (ms)	1653.19	3185.64	6269.82	12463.90	25167.30	13079.88





测试场景五：模型精度测试

测试目标

模型精度测试目标主要是通过标准指标（如准确率、精确率、召回率、F1值、mAP、AUC）衡量模型在测试集上的输出与真实标签的一致性，评估其基本判别能力。

MiniMax-M2.5模型 - 各测试任务整体比对

Task	nvidia_h100(FP8)	metax_c550(W8A8)	差值	百分比
IFBench (Strict)	0.6067	0.5700	-0.0367	- 6.04%
IFBench (Loose)	0.6433	0.5967	-0.0467	- 7.25%
Im-eval:gsm_plus (Flexible)	0.6863	0.7486	0.0623	+ 9.08%
Im-eval:gsm_plus (Strict)	0.7307	0.7334	0.0027	+ 0.37%
Im-eval:mmlu_pro	0.7378	0.6686	-0.0692	- 9.38%
Im-eval:ruler	0.5461	0.8972	0.3511	+ 64.30%

mmlu_pro任务子数据集详细比对

Item	nvidia_h100(FP8)	metax_c550(W8A8)	差值	百分比
biology	0.8703	0.8173	-0.0530	- 6.09%
business	0.8238	0.7997	-0.0241	- 2.93%
chemistry	0.7836	0.5857	-0.1979	- 25.26%
computer_science	0.8049	0.7341	-0.0708	- 8.80%
economics	0.7974	0.7701	-0.0273	- 3.42%
engineering	0.5851	0.5686	-0.0165	- 2.82%
health	0.7702	0.6675	-0.1027	- 13.33%
history	0.6115	0.5591	-0.0524	- 8.57%
law	0.4759	0.4759	0.0000	+ 0.00%
math	0.8312	0.6758	-0.1554	- 18.70%
other	0.7240	0.7045	-0.0195	- 2.69%
philosophy	0.6814	0.5671	-0.1143	- 16.77%
physics	0.7691	0.7375	-0.0316	- 4.11%
psychology	0.7870	0.7206	-0.0664	- 8.44%

ruler任务子数据集详细比对

Item	nvidia_h100(FP8)	metax_c550(W8A8)	差值	百分比
niah_multikey_1	0.3125	0.9688	0.6563	+ 210.02%
niah_multikey_2	0.7812	1.0000	0.2188	+ 28.01%
niah_multikey_3	0.5312	1.0000	0.4688	+ 88.25%
niah_multiquery	0.2969	0.9844	0.6875	+ 231.56%
niah_multivalue	0.1484	0.9531	0.8047	+ 542.25%
niah_single_1	0.3438	1.0000	0.6562	+ 190.87%
niah_single_2	0.2812	1.0000	0.7188	+ 255.62%
niah_single_3	0.4375	1.0000	0.5625	+ 128.57%
ruler_cwe	0.6281	0.5312	-0.0969	- 15.43%
ruler_fwe	0.8958	0.9479	0.0521	+ 5.82%
ruler_qa_hotpot	0.7500	0.6562	-0.0938	- 12.51%
ruler_qa_squad	0.6927	0.6224	-0.0703	- 10.15%
ruler_vt	1.0000	1.0000	0.0000	+ 0.00%

测试场景六：基础推理能力验证

测试目标：

验证模型在芯片环境上的基础推理和兼容性的支持能力情况，可作为快速选型的一个基础指标。

测试说明

- 比对说明：本章节只列出在MetaX-C550芯片平台上的测试结果
- 状态说明：✅ 已通过，⏳ 未测试，❌ 未通过，⚠️ 部分通过

A. 基础推理能力

#	测试点	测试内容	状态
A1	单轮对话	发送单条prompt，验证正常生成	✓
A2	多轮对话	5轮对话，验证上下文保持和连贯性	✓
A3	System Prompt	设置系统角色，验证模型遵循程度	✓
A4	流式输出	stream=true，验证SSE逐token返回	✓
A5	非流式输出	stream=false，验证完整返回	✓
A6	Temperature 控制	temp=0 vs temp=1.0，验证输出差异	✓
A7	Top-p/Top-k采样	不同top_p/top_k值，验证多样性控制	✓
A8	Max Tokens限制	设置max_tokens，验证输出不超限	✓
A9	Stop Sequences	设置stop token，验证截断	✓
A10	Seed 可复现性	相同seed+temp=0，验证输出一致	✓
A11	多语言能力	中/英/日/韩/法等多语言输入输出	✓
A12	特殊Token处理	含emoji、代码块、数学符号、HTML标签	✓

B. 高级生成功能

#	测试点	测试内容	状态	备注
B1	思考模式 (Thinking)	开启thinking mode，验证返回思考链...	✓	
B2	非思考模式 (Instant)	关闭thinking，验证无hidden th...	✗	使用默认 temperature 0.7
B3	思考模式切换	同一会话内thinking↔non-think...	✗	使用默认 temperature 0.7
B4	工具调用-单工具	定义单个function，验证模型正确调用并传参	✓	
B5	工具调用-多工具	定义多个function，验证模型选择正确的工具	✓	
B6	工具调用-并行调用	单次回复中并行调用多个工具	✓	
B7	工具调用-多步链式	工具结果作为下一步输入，验证3+步链式执行	✓	个别时候会失败
B8	JSON Mode	response_format=json_ob...	✓	
B9	结构化输出	JSON Schema约束输出格式，验证字段完整性	✓	
B10	Prefix/Suffix约束	指定输出前缀或格式模板，验证遵循度	✗	

C. 多模态能力（MiniMax-M2.5模型为文本模型，此测试组请跳过）

#	测试点	测试内容	状态
C1	单图理解	图片+文本提问	×
C2	多图对比	跨图比较	×
C3	高分辨率图片	4K分辨率	×
C4	图表/OCR	表格截图	×
C5	视频理解	视频文件	×
C6	代码截图→代码	UI截图	×
C7	多模态工具调用	图片触发工具	×
C8	图片格式兼容性	PNG/JPEG/WebP	×

D. 长上下文处理

#	测试点	测试内容	状态
D1	短上下文基线	1K tokens	✓
D2	中等上下文	8K-16K tokens	✓
D3	长上下文	32K-64K tokens	✓
D4	超长上下文	128K+ tokens	✓
D5	大海捞针	NIAH	✓
D6	上下文边界行为	max_model_len	✓
D7	超出上下文截断	截断/拒绝	✓
D8	长输出生成	4K-8K tokens	✓

F. 稳定性与边界

#	测试点	测试内容	状态
F1	空输入	空prompt	✓
F2	超大输入	超max_model_len	✓
F3	非法参数	temperature=-1, max_tokens=0,非法温度值：超过范围 (>2)	✓
F4	特殊字符注入	SQL/Prompt注入	✓
F5	并发稳定性	200+并发（实际测试50并发）	✓
F6	OOM恢复	显存耗尽	⌚
F7	长时间运行	24小时	⌚
F8	请求超时处理	超时断开	⌚

G. API兼容性

#	测试点	测试内容	状态
G1	OpenAI Chat Completions	/v1/chat/completions 接口兼容	✓
G2	OpenAI Completions	/v1/completions 接口兼容	✓
G3	模型列表	/v1/models 返回可用模型	✓
G4	Usage 统计	usage 字段准确	✓
G5	错误码规范	400/401/404/429/500 错误码	⌚
G6	客户端 SDK 兼容	Python openai / JS @ope...	⌚
G7	响应格式变体	不同response_format	✓
G8	Stream参数	stream参数测试	✓

H. 质量评估

#	测试点	测试内容	状态
H1	生成质量	质量对比	✓
H2	生成一致性	多次生成	✓
H3	幻觉率	事实错误	✓
H4	指令遵循度	格式/角色	✓
H5	响应相关性	问答相关性	✓

I. 超长上下文验证

#	测试点	测试内容	状态
I1	超长上下文（非流式）	验证超长上下文请求的非流式输出	✓
I2	超长上下文（流式）	验证超长上下文请求的流式输出	✓
I3	超长上下文（边界验证）	使用二分法逼近模型最大上下文长度	✓
I4	超长上下文（思考模式）	验证超长上下文下reasoning_conte...	✓

附录一：MetaX-C550平台Minimax-M2.5模型部署脚本

```
#!/bin/bash
# 10.130.70.2
# 10.130.70.1

mx-smi -r -i all

export PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True,max_split_size_mb:128

# 单机16卡 MCCL 环境变量
#export MCCL_RING_16P1H=1
#export FORCE_ACTIVE_WAIT=1
#export MCCL_P2P_LEVEL=SYS

export GLOO_SOCKET_IFNAME=ens12f0
export MCCL_SOCKET_IFNAME=ens12f0
export MCCL_IB_HCA=m1x5_0,m1x5_1,m1x5_2,m1x5_3,m1x5_4,m1x5_5,m1x5_6,m1x5_7
```

```

export TRITON_ENABLE_MACAP_OPT_MOVE_DOT_OPERANDS_OUT_LOOP=1
export TRITON_ENABLE_MACAP_CHAIN_DOT_OPT=1

# 通用环境变量
export MACA_SMALL_PAGESIZE_ENABLE=1
export TRITON_ENABLE_MACA_OPT_MOVE_DOT_OPERANDS_OUT_LOOP=1
export TRITON_ENABLE_MACA_CHAIN_DOT_OPT=1

# BF16、W8A8-TP2DP8/TP4DP4
export PYTORCH_ENABLE_PG_HIGH_PRIORITY_STREAM=1
export MACA_QUEUE_SCHEDULE_POLICY=1
export MACA_DIRECT_DISPATCH=1

# W8A8-TP16
#export MACA_DIRECT_DISPATCH=1
#export MCDBG_GRAPH_LAUNCH_QUEUE_POLICY=3
#export MACA_GRAPH_LAUNCH_QUEUE_POLICY=3

# W4A16
#export MACA_QUEUE_SCHEDULE_POLICY=1
#export MACA_DIRECT_DISPATCH=1

#export SGLANG_FUSE_MOE_CACHE_ENABLE=0

# 启用Flash_mla的优化（必须按照4.2.1操作更新flashmla）
export MX_ENABLE_FLASH_MLA_OPT=1

# add form 0.5.9
export TORCH_CUDA_ARCH_LIST="8.0 8.6+PTX"

service ssh restart

model_name=MiniMax-M2.5-W8A8
model_path="/data/data_shared/${model_name}"
log_file=./log-sglang-server-master-${model_name}.log

python3 -m sglang.launch_server \
    --model-path $model_path \
    --trust-remote-code \
    --attention-backend flashinfer \
    --quantization w8a8_int8 \
    --served-model-name minimax-m2.5 \
    --tp-size 8 \
    --context-length 196608 \
    --max-running-requests 64 \
    --dist-init-addr 10.130.70.1:36555 \
    --host 0.0.0.0 \
    --port 8000 \
    --nnodes 1 \
    --node-rank 0 \
    --disable-radix-cach \

```

```
--disable-chunked-prefix-cache \  
--tool-call-parser minimax-m2 \  
--reasoning-parser minimax \  
--mem-fraction-static 0.9 2>&1 | tee -a ${log_file}
```

注：reasoning-parser为minimax，思考内容显示在reasoning_content字段里，如果为minimax-append-think，则思考内容会嵌入到content里，以"<think>...</think>"标签对显示

附录二：benchmark执行脚本

执行命令

```
python run_benchmark.py --chip inspur_MetaX_C550 --model MiniMax-M2.5-w8A8 --test-suite test_01,test_02,test_03,test_04,test_05
```

如果不指定test-suite参数，默认执行run_benchmark.py里TEST_SUITES定义的测试套件列表，可以根据自己需要修改默认测试套件

run_benchmark.py

```
import os  
import yaml  
import subprocess  
import requests  
import time  
from datetime import datetime  
from itertools import product  
from pathlib import Path  
  
API_KEY = os.environ.get("API_KEY", "abc123")  
  
TEST_SUITES = ["test_01"]  
  
RUN_ID = "01"  
  
try:  
    from gpu_monitor import GPUMonitor, generate_gpu_charts  
  
    HAS_GPU_MONITOR = True  
except ImportError:  
    HAS_GPU_MONITOR = False  
    print("Warning: GPU monitor module not available")  
  
def get_model_info_from_api(base_url, api_key):  
    headers = {"Authorization": f"Bearer {api_key}"}  
    try:
```

```

        response = requests.get(f"{base_url}/v1/models", headers=headers,
                                timeout=10)
        if response.status_code == 200:
            data = response.json()
            if data.get("data") and len(data["data"]) > 0:
                model_info = data["data"][0]
                model_name = model_info.get("id")
                owned_by = model_info.get("owned_by")
                model_path = model_info.get("root")
                if owned_by == "sglang" and model_path:
                    return model_name, model_path
                else:
                    return model_name, None
        except Exception as e:
            print(f"Failed to get model info from API: {e}")
        return None, None

def run_benchmark(chip_name, base_config, model_config, test_suites, run_id):
    base_url = base_config.get("base_url", "http://127.0.0.1:8000")

    model_name_yaml = model_config.get("name")
    served_model_name = model_config.get("served-model-name")
    model_path_yaml = model_config.get("model_path")

    if not model_path_yaml:
        print(f"Error: model_path is required in config for model
        '{model_name_yaml}'")
        return

    model_name, model_path = get_model_info_from_api(base_url, API_KEY)

    if not model_name:
        model_name = served_model_name
    model_path = model_path_yaml

    print(f"Model Name: {model_name}")
    print(f"Model Path: {model_path}")
    print(f"Running test suites: {' '.join(test_suites)}")

    temperature = base_config.get("temperature", 0.7)
    seed = base_config.get("seed", 123)
    ready_timeout = base_config.get("ready-check-timeout-sec", 30)

    M = model_name_yaml
    output_base = f"reports/benchmark/{chip_name}/{M}"

    params_config = base_config.get("params", {})

    for test_suite in test_suites:
        test_params = params_config.get(test_suite, {})
        max_concurrency = test_params.get("max-concurrency", [10])
        num_prompts = test_params.get("num-prompts", [300])

```

```

random_input_output_len = test_params.get(
    "random-input-output-len", [[20000, 100]]
)

run_id_dir = os.path.join(output_base, test_suite, run_id)
if os.path.exists(run_id_dir):
    print(
        f"Error: Run ID '{run_id}' already exists for test suite '{test_suite}' at path: {run_id_dir}"
    )
    print(f"Please either:")
    print(f"  1. Use a different RUN_ID (--run-id)")
    print(f"  2. Delete the existing directory: {run_id_dir}")
    continue

print(f"\n=== Running test suite: {test_suite} ===")

gpu_monitor = GPUMonitor(interval=10) if HAS_GPU_MONITOR else None

for nc, np, io_len in product(
    max_concurrency, num_prompts, random_input_output_len
):
    ni = io_len[0]
    no = io_len[1]
    param_dir = f"{test_suite}/{run_id}/{nc}-{np}-i{ni}-o{no}"
    output_dir = os.path.join(output_base, param_dir)
    Path(output_dir).mkdir(parents=True, exist_ok=True)

    log_file = os.path.join(
        output_dir, f"bench-{test_suite}-{nc}-{np}-i{ni}-o{no}.log"
    )

    jsonl_file = os.path.join(
        output_dir, f"bench-{test_suite}-{nc}-{np}-i{ni}-o{no}.jsonl"
    )

    if gpu_monitor:
        gpu_monitor.start_monitoring(
            "monitor/logs", chip_name, model_name_yaml, param_dir
        )

    cmd = [
        "python3",
        "-m",
        "sglang.bench_serving",
        "--backend",
        "sglang",
        "--dataset-name",
        test_params.get("dataset-name", "random"),
        "--random-range-ratio",
        "1.0",
        "--host",
        "0.0.0.0",
    ]

```

```

        "--port",
        str(base_config.get("port", 8000)),
        "--random-input-len",
        str(ni),
        "--random-output-len",
        str(no),
        "--max-concurrency",
        str(nc),
        "--num-prompt",
        str(np),
    ]

    if model_path_yaml:
        cmd.extend(["--model", model_path_yaml])

    cmd.extend(["--output-file", jsonl_file])

    print(f"Running: {' '.join(cmd)}")
    print(f"Log file: {log_file}")

    log_f = open(log_file, "w")
    process = subprocess.Popen(
        cmd, stdout=subprocess.PIPE, stderr=subprocess.STDOUT, text=True
    )

    for line in process.stdout:
        print(line, end="")
        log_f.write(line)

    process.wait()
    log_f.close()

    if gpu_monitor:
        gpu_log = gpu_monitor.stop_monitoring()
        if gpu_log:
            gpu_log_dir = os.path.dirname(gpu_log)
            generate_gpu_charts(gpu_log, gpu_log_dir)

    print(f"Completed: {log_file}")
    time.sleep(30)

def main():
    import argparse

    parser = argparse.ArgumentParser(description="Run SGLang benchmark")
    parser.add_argument(
        "--chip",
        type=str,
        required=True,
        help="Chip name to test (e.g., inspur_MetaX_C550, hygon_bw1000, kunlun_p800, nvidia_h100)",
    )

```



```

parser.add_argument(
    "--model",
    type=str,
    default=None,
    help="Model name to test (e.g., minimax-m2.5, Qwen3.5). If not specified,
uses the first model in config.",
)
parser.add_argument(
    "--test-suite",
    type=str,
    default=None,
    help=f"Test suite to run (default: all). Available: {'',
'.join(TEST_SUITES)}",
)
parser.add_argument(
    "--run-id",
    type=str,
    default=RUN_ID,
    help=f"Run ID to identify this test run (default: {RUN_ID})",
)
args = parser.parse_args()

yaml_path = os.path.join(
    os.path.dirname(__file__), "config", "models_scenarios.yaml"
)

with open(yaml_path, "r", encoding="utf-8") as f:
    config = yaml.safe_load(f)

base_config = config.get("base_config", {})
params_config = base_config.get("params", {})
models = config.get("models", {})

chip_name_input = args.chip
chip_name_lower = chip_name_input.lower()

chip_name = None
for key in models.keys():
    if key.lower() == chip_name_lower:
        chip_name = key
        break

if chip_name is None:
    print(
        f"Error: Chip '{chip_name_input}' not found in config. Available chips:
{'', '.join(models.keys())}"
    )
    return

available_models = models[chip_name]

if args.model:
    model_name_input = args.model

```

```

model_name_lower = model_name_input.lower()
selected_model = None
for m in available_models:
    if m.get("name", "").lower() == model_name_lower:
        selected_model = m
        break
        break
if not selected_model:
    print(
        f"Error: Model '{args.model}' not found for chip '{chip_name}'.
Available models:"
    )
    for m in available_models:
        print(f" - {m.get('name')} (served: {m.get('served-model-name')})")
    return
model_configs = [selected_model]
else:
    model_configs = available_models

test_suites_to_run = []
if args.test_suite:
    test_suites_to_run = [s.strip() for s in args.test_suite.split(",")]
else:
    test_suites_to_run = TEST_SUITES

invalid_suites = [s for s in test_suites_to_run if s not in params_config]
if invalid_suites:
    print(
        f"Error: Test suite(s) {invalid_suites} not found in config. Available:
{' , '.join(params_config.keys())}"
    )
    return

run_id = args.run_id

for model_config in model_configs:
    print(f"Processing chip: {chip_name}, model: {model_config.get('name')}")
    run_benchmark(chip_name, base_config, model_config, test_suites_to_run,
run_id)
    print(f"Finished chip: {chip_name}, model: {model_config.get('name')}")

if __name__ == "__main__":
    main()

```

九章云极