

浪潮MetaX-C550、英伟达H100 - 单节点MiniMax-M2.5模型整体测试比对报告

*测试日期：2026-04-22 ~ 2026-04-26

*测试人员：九章云极

1. 测试场景及概况

1.1 测试场景列表

序号	测试场景
场景一	sglang benchmark基准测试
场景二	单、多并发超长上下文请求

1.2 模型推理测试问题汇总

- 关闭思考模式不生效**，关闭思考模式后，请求响应输出依然有思考模型下的content: 如果parser是minimax-append-think, 思考的内容会在content里以...标签对包裹。如果parser是minimax，思考的内容会直接显示在reasoning_content里


测试场景一：sglang/vllm benchmark基准测试

测试概览

项目	配置	备注
数据集	inspur_MetaX_C550 (ShareGPT_V3_unfiltered_cleaned_split.json, random), nvidia_h100 (random)	
并发数	1, 2, 4, 8, 10, 16, 32, 64, 80, 128	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
被测芯片	inspur_MetaX_C550, nvidia_h100	
被测模型	inspur_MetaX_C550 (MiniMax-M2.5-W8A8), nvidia_h100 (MiniMax-M2.5)	


芯片性能对比柱状图

1并发





性能趋势对比图



各指标随并发级别性能对比详情

总token吞吐量 (Total token throughput (tok/s))

并发数	inspur_MetaX_C550	nvidia_h100
1	2839.48	4745.14 ★
2	4336.07	8217.92 ★
4	6617.46	13310.92 ★
8	8757.21	19176.39 ★
10	9540.82	21996.95 ★
16	11348.92	26494.03 ★
32	13322.11	32831.81 ★
64	14744.38	38566.45 ★
80	14765.49	38638.21 ★
128	14756.01	38585.00 ★

首token延迟（P99 TTFT (ms)）

并发数	inspur_MetaX_C550	nvidia_h100
1	596.38	286.01 ★
2	1097.81	466.40 ★
4	2137.97	826.89 ★
8	4216.68	1364.44 ★
10	5277.45	1534.23 ★
16	8059.86	2630.84 ★
32	15782.91	6556.86 ★
64	31672.66	12557.76 ★
80	53556.78	19679.20 ★
128	76792.15	29645.32 ★

测试场景二：超长上下文请求测试

测试目标：对超长上下文的请求，使用sglang/vllm bench serve工具对并发数逐级增加场景的性能基准验证。


 测试概览

项目	配置	备注
数据集	inspur_MetaX_C550 (ShareGPT_V3_unfiltered_cleaned_split.json), nvidia_h100 (random)	
并发数	1, 2, 4, 8, 10	
总请求数	100	
请求输入上下文长度	194560 (190k)	
请求输出上下文长度	1024 (1k)	
被测芯片	inspur_MetaX_C550, nvidia_h100	
被测模型	inspur_MetaX_C550 (MiniMax-M2.5-W8A8), nvidia_h100 (MiniMax-M2.5)	



芯片性能对比柱状图

1并发



各并发级别性能对比详情

Total token throughput (tok/s)

并发数	inspur_MetaX_C550	nvidia_h100
1	2424.14	8921.40
2	2610.79	11850.06
4	2739.69	13726.45
8	2741.37	14443.68
10	2739.59	14398.41

P99 TTFT (ms)

并发数	inspur_MetaX_C550	nvidia_h100
1	63374.54	10539.10 ★
2	126438.40	20205.87 ★
4	252746.14	37530.99 ★
8	550123.80	81506.35 ★
10	721962.01	108342.29 ★
